

Исполняемые эпистемические контракты в детерминированной симуляции агентов: архитектура ENIGMA¹

4Um4

Independent Researcher

<https://github.com/4Um4>

17 сентября 2026 г.

Аннотация

В большинстве современных симуляций агентов на основе больших языковых моделей (LLM) убеждения агентов реализуются как промпты или структуры для вербализации, а расхождение убеждений возникает как побочный эффект стохастической генерации текста и не поддаётся проверке. Мы представляем ENIGMA — детерминированную многоагентную архитектуру, в которой расхождение убеждений является первоклассным, каузально значимым и исполняемо проверяемым свойством симуляции. Ядро архитектуры образуют: ExperienceTrace с первоклассным провенансом (восприятие, свидетельство, интроспекция), мембрана восприятия, строго отделяющая истину мира от наблюдений агентов, шлюз DeltaGate как единственный легальный вход «интерпретация → состояние», изолирующий LLM от каузального ядра, и BeliefCrystallizationEngine с асимметричной травмой ($\times 6$) и энтропийным затуханием ($\tau = 100$ тиков). Методологический вклад — исполняемые эпистемические контракты (SUPERBOX): сценарии, превращающие эпистемические утверждения в бинарные проверяемые вердикты. Мы приводим воспроизводимые прогоны в протоколе свежей распаковки: 45/45 инвариантных проб ядра, детерминированность ревизии убеждений, измеренную асимметрию обновления, распространение одного слуха с различной уверенностью у разных слушателей и подтверждённую позитивным контролем каузальность «убеждение → решение»: наблюдение кражи четырьмя агентами порождает убеждения с уверенностью 0.9, диспозиционные модификаторы решений и смену интента. Мы также предъявляем честный аудит сценариев, дающих в исследуемом снапшоте красный вердикт: красные вердикты не замалчиваются — они показывают, что контракты работают как диагностический инструмент, а не декорация. Работа позиционируется строго как вклад уровня систем и воспроизводимая референсная реализация, а не как новая психологическая теория.

Ключевые слова: детерминированная симуляция агентов; эпистемика; ревизия убеждений; исполняемые контракты; провенанс; LLM-агенты; Theory of Mind.

1. Введение

Симуляции агентов на основе больших языковых моделей переживают бурный рост: от «генеративных агентов» Парка и коллег [1] с двадцатью пятью персонажами в sandbox-среде до социальных симуляторов масштаба миллиона агентов [2]. В этих системах агентам приписываются память, рефлексия, планы и убеждения, и получаемое поведение часто выглядит убедительно. Однако на архитектурном уровне убеждение в таких системах — это, как правило, текст в промпте или запись в языковой памяти: оно влияет на следующую реплику LLM, но не является состоянием, чья динамика подчинялась бы проверяемым правилам. Расхождение убеждений двух агентов — центральный механизм социальной драмы, лжи, слухов и недоразумений — возникает там

¹Полный исходный код проекта доступен по адресу <https://github.com/4Um4/Enigma/> (версия V.0.5.4.0.6). Все числовые результаты в разделах 5 получены прогонами этой версии в изолированной среде без LLM-сервера; команды воспроизведения приведены в разделе «Доступность».

как побочный эффект стохастичности генерации, а не как спроектированное и контролируемое свойство системы.

Следствием является эпистемическая непроверяемость. Утверждение «агент *A* верит, что *B* украл кольцо» в LLM-центричной архитектуре можно подтвердить только новым опросом модели, чей ответ нестабилен и зависит от формулировки промпта. Нельзя воспроизвести момент формирования убеждения, нельзя восстановить его происхождение (увидел ли агент событие сам или узнал со слов третьего лица), нельзя доказать, что именно убеждение, а не шум генерации, изменило решение агента. Для исследований, где расхождение убеждений — предмет изучения, а не декорация, этого недостаточно.

Настоящая статья описывает ENIGMA — исследовательский прототип детерминированного каузального движка симуляции, в котором эпистемическое расхождение агентов является первоклассным свойством. Главный тезис таков: *мы предъявляем детерминированную многоагентную архитектуру, в которой расхождение убеждений — первоклассное, каузально значимое свойство симуляции, а каждое эпистемическое утверждение о системе превращается исполняемым сценарием в бинарный воспроизводимый вердикт; сценарии переживают сохранение и загрузку состояния и перезапуск сессии.* Детерминизм при этом не делает мир предсказуемым для игрока — он делает эпистемику инспектируемой для исследователя: игрок видит мир через собственную эпистемическую границу, и скрытое состояние других агентов делает их поведение информационно непредсказуемым при полной механической воспроизводимости.

Вклад работы состоит в следующем:

1. **Онтология и провенанс.** Трёхчастная онтология «истина мира — наблюдение — убеждение», в которой единица опыта ExperienceTrace несёт первоклассный провенанс (PERCEPTION, TESTIMONY, INTROSPECTION), а свидетельство допускает *owner* $\neq$ *actor* (раздел 3).
2. **Эпистемическая мембрана и шлюз DeltaGate.** Архитектурная изоляция LLM от каузального ядра: язык модели не может стать источником истины; любая интерпретация проходит whitelist, клампы и идемпотентный контроль (раздел 3).
3. **Асимметричная модель кристаллизации убеждений.** Измеримая динамика обновления с множителем травмы 6, экспоненциальным затуханием и порогом забывания, формализующая negativity bias в вычислимой форме (раздел 3).
4. **Исполняемые эпистемические контракты.** Набор SUPERBOX-сценариев как метод оценки: каждое архитектурное утверждение получает бинарный, воспроизводимый вердикт; красный вердикт трактуется как диагностика, а не замалчивается (разделы 4, 5).
5. **Честный аудит.** Подтверждённые вердикты обоих знаков: шестнадцать зелёных проверок (включая позитивный контроль каузальности «убеждение → решение» через канал наблюдения и гейт обвинения, в котором убеждение игрока — игровая способность) и красные вердикты с точным диагнозом каждого разрыва цепи (раздел 5).

Мы сознательно позиционируем работу как вклад уровня систем (systems contribution) и воспроизводимую референсную реализацию, а не как новый алгоритм или психологическую теорию. claims в тексте привязаны к конкретным модулям кода и конкретным сценариям; «имя класса не является доказательством семантики» — рабочий принцип проекта, и мы придерживаемся его при изложении.

2. Связанные работы

Симуляторы агентов на основе LLM. Генеративные агенты [1] комбинируют memory stream, рефлекссию и планирование; состояние агента — текстовое, а «убеждение» существует лишь постольку, поскольку оно отражено в памяти, из которой собирается промпт. OASIS [2] масштабирует этот подход до миллиона агентов в структурированной социальной среде, но эпистемика

агентов остаётся проекцией текста. Наиболее близкая к нашей задаче система — BeliefNest [3]: открытый симулятор для embodied-агентов в Minecraft с явными вложенными состояниями убеждений (включая задачи на ложные убеждения). Однако представления убеждений там обслуживают генерацию промптов и оценку ToM-рассуждений LLM, тогда как в ENIGMA убеждение — состояние детерминированного ядра, чьё формирование, происхождение и каузальная роль контролируются контрактами движка. Обзоры LLM-агентов [4] подтверждают, что эпистемический слой с гарантиями — редкость: обычно он либо отсутствует, либо реализуется внутри самой модели.

Ревизия убеждений и психология асимметрии. Классическая теория ревизии убеждений AGM [5] постулирует рациональные постулаты изменения убеждений при поступлении новой информации; наша операция ревизии проще (взвешивание по надёжности источника, эхо-демпфирование повторов), но, в отличие от AGM, выполняется как часть тика симуляции и потому проверяема на живых траекториях. Психологическая литература документирует устойчивую асимметрию негатива: негативная информация сильнее позитивной при равной интенсивности [6, 7]. Множитель травмы 6 в BeliefCrystallizationEngine — осознанная инженерная формализация этого эффекта: опровержение доверия должно обходиться дороже его подтверждения.

Theory of Mind и ложные убеждения. Классика ToM [8] и парадигма ложных убеждений [9] дают готовую форму для проверки: агент, не наблюдавший событие, должен продемонстрировать убеждение, расходящееся с истиной. Наш эталонный сценарий «двойная истина» (раздел 4) — вычислительный аналог задачи Салли и Энн: три агента, один эпизод, три разных эпистемических мира, при этом расхождение обязано транслироваться в расхождение решений.

Инженерия контрактов. Идея проектирования по контракту [10] и runtime-верификация [11] переносятся нами на эпистемические свойства: постусловиям и инвариантам соответствуют исполняемые сценарии SUPERBOX, а нарушению контракта соответствует исключение времени выполнения (ArchitecturalViolationError) либо красный вердикт сценария. В отличие от традиционной runtime-верификации, где монитор наблюдает за системой извне, наши контракты встроены в цикл разработки как acceptance-гейты: система считается реализованной только при зелёном вердикте — принцип «утверждение → код → путь вызова → тест → наблюдаемый результат».

Когнитивные архитектуры. Системы уровня Soar [12] десятилетиями реализуют процедурную память и правила как исполняемые структуры. ENIGMA не претендует на общность Soar; она исследует узкий, но плохо освещённый вопрос: как сделать *эпистемическое состояние* агента (что он знает, откуда и насколько уверен) такой же инженерно проверяемой подсистемой, как рабочая память или планировщик.

3. Архитектура ENIGMA

3.1. Онтология: истина, наблюдение, убеждение

Движок никогда не схлопывает три категории в одно состояние: *истина мира* (что произошло в симуляции), *наблюдение* (к чему агент имел физический доступ) и *убеждение* (во что агент верит сейчас). Формально состояние симуляции в тике t есть

$$S_t = (W_t, \{S_i^t\}_{i=1}^N, \mathcal{E}_t, C_t),$$

где W_t — мир (снимок состояния и объекты), S_i^t — состояние агента i (тело, память, восприятие, отношения, психика), $\mathcal{E}_t$ — эпистемические записи убеждений, C_t — активные обязательства. Переход между тиками задаётся оператором

$$S_{t+1} = \Phi(S_t, E_t), \quad \Phi = \phi_{10} \circ \dots \circ \phi_0,$$




Рис. 1: Архитектура ENIGMA: каузальный конвейер (слева) от мира W_t через мембрану восприятия и ExperienceTrace к убеждениям, решениям и действиям; граница LLM с шлюзом DeltaGate (справа сверху) и системные гарантии детерминизма (справа). Красная стрелка — единственный легальный вход «интерпретация → состояние».

где E_t — события тика, а Φ — конкатенация фаз тик-оркестратора (13 фаз, pure reducer): фазы формируют дельты, мутация состояния выполняется единственным применителем — **State Applicator**; коммит — атомарный и единственный за тик.

Ключевой инвариант онтологии (S188): *коммуникативное утверждение никогда не является истиной мира и никогда напрямую не мутирует хранилище отношений*. Убеждение — состояние сознания агента, а не факт мира; ложь, принятая на веру, меняет психику слушателя, но не историю вселенной. На этой аксиоматике держатся все дальнейшие механизмы.

3.2. ExperienceTrace: опыт с первоклассным провенансом

Единицей интерпретации воспринятого события служит **ExperienceTrace** (контракт E1.0) — immutable-запись с обязательным провенансом. Поле `source_type` принимает три значения: **PERCEPTION** (агент воспринял сам), **TESTIMONY** (узнал со слов другого агента — тогда `source_id` указывает рассказчика) и **INTROSPECTION** (собственное действие или состояние). Триада участников — `actor_id` (кто совершил событие), `owner_id` (чей это опыт) и `source_id` (откуда владелец знает) — делает принципиальным случаем $owner \neq actor$: опыт свидетеля чужой кражи и опыт самого вора — разные записи с разной семантикой доверия.

Идемпотентность обеспечивается идентичностью записи: (эпизод, владелец), а для свидетельства — (эпизод, владелец, источник). Повторная доставка того же события не создаёт дублей опыта. Сигнальные поля (валентность, возбуждение, новизна, релевантности) являются проекциями и заполняются резолвером, а не самой записью: **ExperienceTrace** — не источник истины (SSOT остаётся за событийной памятью), а интерпретация над ней.

3.3. Мембрана восприятия

Мир попадает в «голову» агента только через мембрану восприятия. Видимость события определяется функцией `can_observe`: приватные события видит только источник, шёпот — источник и адресат, публичные — все, кто находится в радиусе слышимости (сравнение евклидова расстояния с радиусом события). Подписчик коммуникативных событий строит множество слушателей по пространственному запросу сцены: адресат реплики остаётся семантическим получателем, но физически слышит её лишь тот, кто находится рядом; «телепатия» (передача убеждений без физического контакта) запрещена. Зрение, аналогично, ограничено полем видимости, а эмбодимент всех агентов, включая игрока, подчинён единым физическим законам.

3.4. DeltaGate: единственный вход в состояние

Между любой интерпретацией (в том числе порождённой LLM) и состоянием агента стоит шлюз **DeltaGate** (контракт E2.0). Его инвариант сформулирован прямо в коде: без применения шлюза ни одна интерпретация — включая LLM-порождённую — не меняет ни одного поля психики. Механизм тройной:

1. **Whitelist полей.** Разрешены только два поля: `threat_gradient` с диапазоном $[-1, 1]$ (потребитель — `perceptual_kernel`) и `danger_belief` с диапазоном $[0, 1]$ (потребитель — `r7_beliefs`); попытка записи иного поля отклоняется с предупреждением в лог.
2. **Клампы.** Значение зажимается в допустимый диапазон до диспетчеризации потребителю.
3. **Идемпотентность.** Ключ (идентификатор трейса, поле) запоминается; повторная дельта того же трейса молча пропускается.

Каждое применение публикует событие **EXPERIENCE_DELTA_COMMITTED** с полной причинной трассировкой (трейс, причинный родитель, поле, значение, потребитель) — единственный выход для хрониста. Роль LLM в этой архитектуре — «медленный консультант»: языковая модель

ведёт диалоги и вербализацию, быстрый мир (тики) никогда не ждёт медленного интеллекта (доктрина двух скоростей), и ни одна сгенерированная фраза не становится фактом мира без детерминированной авторизации мутации. LLM — не субстрат интеллекта ENIGMA; детерминированное ядро владеет состоянием, временем, каузальностью, памятью, убеждениями и решениями.

3.5. Ревизия убеждений: надёжность источника и эхо-демпфирование

Свидетельство обрабатывается **BeliefRevisionEngine** — детерминированным движком, не использующим LLM и не мутирующим отношения. Надёжность источника r вычисляется провайдером (единственным владельцем формулы) из доверия τ слушателя к говорящему:

$$r(\tau) = \begin{cases} 0.9, & \text{прямое наблюдение (DOR),} \\ \text{clamp}(\tau/100, 0, 1), & \tau \geq -30, \\ -\frac{|\tau| - 30}{70}, & \tau < -30. \end{cases}$$

Априорная надёжность неизвестного источника ($\tau_0 = 50$) равна 0.5; враг ($\tau = -100$) даёт $r = -1$ (его слова активны в обратную сторону, но не ниже нуля). Непрерывность в $\tau = -30$ и монотонность всюду проверены инвариантом INV-EPISTEMIC-TRUST-MONOTONICITY.

Входящая уверенность $c_{\text{in}} = r \cdot w$ (w — вес утверждения, 1.0) обновляет запись по трём веткам:

$$c' = \begin{cases} \max(0, c_{\text{in}}), & \text{новая запись,} \\ \text{clamp}(c + 0.2 c_{\text{in}}), & \text{тот же источник (эхо),} \\ \text{clamp}(c + c_{\text{in}}), & \text{независимый источник.} \end{cases}$$

Демпфирование $\times 0.2$ повторов того же рассказчика препятствует накачке уверенности эхом одной сплетни; полное слагаемое доступно лишь независимому подтверждению. Каждая запись **EpistemicRecord** хранит провенанс: источник, идентификатор исходного утверждения, тики первого наблюдения и последнего обновления.

3.6. Кристаллизация убеждений: асимметричная травма и энтропия

Долговременные межличностные убеждения формируются движком кристаллизации **Belief CrystallizationEngine** (слой L2.5) из агрегированной статистики паттернов, которую строит **PatternDetector** (L1.5) поверх append-only хроники L1. Статистика — чистая: кумулятивный эффект cum и поведенческая дисперсия, без психологических полей; психологию добавляет только кристаллизатор. Базовый вес эпизода

$$w_{\text{base}} = \min(|\text{cum}|/10, 1) \cdot s, \quad s = \begin{cases} s_{\text{fear}}, & \text{cum} < 0, \\ s_{\text{signif}} + s_{\text{desire}}, & \text{cum} > 0, \end{cases}$$

модулируется личностью (чувствительностью к угрозам или к значимости). Правила обновления веса:

$$\text{подтверждение: } w' = \min(w + w_{\text{base}}, 1); \quad \text{опровержение: } w' = w - 6 w_{\text{base}},$$

где множитель травмы равен 6 (константа **TRAUMA_MULTIPLIER**, ADR-O-307): опровержение доверия в шесть раз сильнее его подтверждения. Если вес опровергнутого убеждения падает до нуля — старое стирается и может сформироваться новое (противоположного знака); новое убеждение создаётся при $w_{\text{base}} > 0.05$.

Второй компонент динамики — энтропийное затухание:

$$w(t) = w(t_0) e^{-\Delta t/100}, \quad \tau_{\text{decay}} = 100 \text{ тиков},$$

с порогом забывания $w \leq 0.05$: убеждение, не подкрепляемое новыми эпизодами, теряет половину веса за $\tau \ln 2 \approx 69.3$ тика и стирается примерно через 300 тиков. Кристаллизованные убеждения входят в слой L3 (эффективные драйвы) и далее в полезность решений.

3.7. Детерминизм: KernelRNG, single-writer и append-only хроника

Воспроизводимость обеспечивается на трёх уровнях. Во-первых, единственный источник случайности в ядре — `KernelRNG`, сид которого вычисляется детерминированно:

$$\text{seed} = \text{SHA-256}(\text{tick} : \text{npc_id} : \text{salt}).$$

Одинаковые пары $(\text{tick}, \text{npc_id})$ дают идентичные последовательности, разные агенты или тики — независимые; прямое использование `random.*` и `time.time()` в слое ядра запрещено профильным линтером. Целевая формула воспроизводимости: *начальное состояние + сид + действия игрока + последовательность тиков* → *воспроизводимая симуляция*.

Во-вторых, запись критических состояний защищена `guard`’ами единственного писателя: метод `update()` состояния убеждений проверяет модуль вызывающего по `whitelist` легальных `writer`’ов; прямая запись мимо `BeliefTransitionEngine` поднимает `Architectural ViolationError` — попытка обхода становится падением теста, а не молчаливой порчей состояния. В-третьих, хроника идентичности `L1Chronicle` — `append-only` журнал в `SQLite` с уникальным констрейнтом пятёрки (кампания, цель, тик, источник, тип события): история лишь растёт; архивация старых событий переносит записи в архив, ничего не удаляя.

Общая схема потоков приведена на рис. 1: вертикальный каузальный конвейер от мира через мембрану и опыт к убеждениям, решениям и действиям; справа — граница LLM с шлюзом `DeltaGate` и системные гарантии детерминизма.

4. Исполняемые эпистемические контракты

Утверждение о системе в ENIGMA считается реализованным только при прохождении исполняемого сценария: *claim* → *код* → *путь вызова* → *тест* → *наблюдаемый результат*. Хранилище сценариев `SUPERBOX` одновременно является `acceptance-гейтом` для эпистемических утверждений: каждый сценарий доказывает один каузальный контракт цепочки «убеждение → решение → действие → событие мира» и завершается бинарным вердиктом. Провалом проекта считались бы: все агенты видят объективную истину; убеждения — алиасы состояния мира; диалог утверждает убеждение, которое движок не использует; LLM изобретает факт, которому нет пути в состояние.

Эталонный сценарий «двойная истина» (`SUPERBOX-001/003`) устроен так. Мир: трое агентов *A*, *B*, *C*; *A* и *B* не дружат. Событие: *A* крадёт предмет у *B*; *B* видит кражу; *C* не присутствует. Коммуникация: *A* говорит *C*, что украл *B*. Ожидаемый исход: *B* верит (из восприятия), что виновник — *A*; *C* верит (из свидетельства с доверием к *A*), что виновник — *B*; в одном и том же мире *B* и *C* действуют по-разному — *C* враждебен к *B* из-за ложного убеждения. Существенно, что сценарий не инжектирует убеждение напрямую: инжектируется только причина — событие коммуникации.

Перечень ключевых контрактов сведён в табл. 1. Столбец «вердикт» отражает результаты наших прогонов снапшота `V.0.5.4.0.6` в протоколе свежей распаковки (раздел 5); исторические зелёные вердикты авторской среды задокументированы в журнале мутаций проекта (`S186–S211`).

Методологическое отличие `SUPERBOX` от обычных юнит-тестов — уровень утверждения. Юнит-тест проверяет функцию; контракт `SUPERBOX` проверяет инженерное заявление об архитектуре: «расхождение убеждений каузально значимо» нельзя проверить функцией, но можно проверить прогоном мира. Именно поэтому вердикты табл. 1 читаются как эпистемический аудит системы, а красные ячейки — как равноправные результаты: они точно указывают, где каузальная цепь разорвана в данном снапшоте, что и продемонстрировано в разделе 5.9.

Таблица 1: Исполняемые эпистемические контракты SUPERBOX (снапшот V.0.5.4.0.6, протокол свежей распаковки).

Контракт	Проверяемое свойство	Вердикт
Ядро детерминизма (IPT)	45 инвариантных проб: кардинальность коммита, round-trip состояния, FSM-зомби, топология объектов	зелёный
Эпистемическое ядро (S-002)	ревизия детерминирована, провенанс, разделение истины/убеждения, независимое подтверждение	зелёный
Single-writer (D3)	прямая запись в убеждения мимо движка поднимает <code>ArchitecturalViolationError</code>	зелёный
Канал наблюдения (O-360)	LOS, дистанция и стены: наблюдение $c=0.9$; телепатии нет; истина мира неизменна	зелёный
Диспозиции (S211)	один <code>belief</code> → разные словари модификаторов по архетипам; детерминизм	зелёный
Каузальность: DecisionHub	модификаторы ($c=0.9$, <code>guard</code>) меняют интен <code>warn</code> → <code>report</code> , <code>score</code> $0.225 \rightarrow 2.093$	зелёный
Каузальность: полный цикл (CAUSAL-POS)	THEFT → 4 наблюдателя ($c=0.9$) → диспозиционные сдвиги → смена интен <code>t</code>	зелёный
Каузальность: testimony (S-004/010)	слух от агента с доверием -0.4 даёт $c=0$ и не меняет решение	красный ^a
Мембрана: коммуникация (S-008)	адресат вне радиуса слышимости не получает убеждения	красный ^b
Персистентность (S-009)	убеждения переживают <code>save/load</code> и перезапуск цикла	зелёный
Игрок (S-014/015)	реплики NPC → убеждения игрока (друг 0.8 , враг 0.0)	зелёный
ACCUSE-гейт (S211)	убеждение ≥ 0.5 — игровая способность; ложное обвинение проходит	зелёный
Второй порядок (S-013)	агент верит, что другой агент утверждает P	требует LLM ^c

^a цепь работает, но каузальная сила свидетельства гейтируется надёжностью источника (см. позитивный контроль); ^b радиус события по умолчанию 999 допускает далёкого слушателя; мембрана наблюдения проходит все проверки; ^c канал события в состоянии требует живого LLM-сервера.

5. Экспериментальная оценка

5.1. Условия эксперимента

Все результаты получены прогонами снапшота V.0.5.4.0.6 в изолированной Linux-среде без LLM-сервера. Это существенное условие: детерминированное ядро спроектировано так, чтобы переживать недоступность «медленного консультанта» — тик продолжается, а LLM-зависимые подзадачи деградируют с наблюдаемой ошибкой в журнале (никаких тихих отказов). Сами сценарии исполняются штатно через стандартные точки входа проекта. Второе условие — *протокол свежей распаковки*: каждое семейство прогонов стартует из нетронутого архива релиза. Песочница сохраняет мировое состояние между запусками (счётчик тиков, позиции, отношения), и накопленная история меняет вердикты сценариев — эффект задокументирован в разделе 5.9; свежая распаковка устраняет его, а все числа ниже воспроизводимы из этого состояния.

5.2. Детерминированное ядро

Набор инвариантных проб ядра (IPT) прошёл полностью: **45 из 45** проб за приблизительно 5 секунд. Пробы включают property-based тесты (round-trip состояния NPC на 200 примерах, отклонение вырожденных координат на 100 примерах, обнаружение FSM-«зомби» на 100 примерах), кардинальность коммита (ровно один коммит за тик), топологию объектов мира (24 живых объекта) и поведенческие замки. Микропроверка `KernelRNG`: последовательности для одинаковой пары (42, `prc_a`) совпали побитово (0.630546, 0.838969, ...), а для другой пары (42, `prc_b`) и следующего тика (43, `prc_a`) независимы. Однописательный `guard` проверен падением: прямая запись `state.beliefs` из произвольного модуля поднимает `ArchitecturalViolation`

Error (тест пройден). Счётчик инвариантов монотонен по истории разработки проекта: 39/39 на S190, 44/44 на S204, 45/45 в исследуемом снапшоте — и 45/45 в журнале авторской среды.

5.3. Эпистемическое ядро

Сценарий SUPERBOX-002 прошёл все четыре проверки. (1) Из `ClaimEvent` создано убеждение с точной арифметикой: уверенность равна 0.80 ($r \cdot w = 0.8 \cdot 1.0$), провенанс сохранён — источник и идентификатор утверждения. (2) Железный инвариант: после принятия лжи на веру объективная истина мира не изменилась — истина и убеждение остаются разделёнными состояниями. (3) Детерминированность: повторная ревизия того же утверждения породила запись, побитово равную первой. (4) Независимое подтверждение второго источника ($r = 0.4$) подняло уверенность $0.80 \rightarrow 1.00$ (кламп на 1.0), тогда как эхо того же рассказчика прибавило бы лишь 0.08. Интеграция ядра в каузальную машину подтверждена отдельными сценариями: убеждение создаётся публикацией `COMMUNICATION_CLAIM` на `EventBus` (провенанс и истина мира не тронуты), проекция `EpistemicStore` $\rightarrow$ `EpistemicContext` (угрозы, союзники, нарушения) детерминирована и не мутирует стор, а компоновка `EpistemicContext` в `DecisionContext` сохраняет инкапсуляцию: `DecisionHub` читает угрозы, не зная о существовании `Proposition` и стор.

5.4. Канал наблюдения и диспозиции

Второй канал поступления убеждений — прямое наблюдение мировых событий (ADR-O-360, сценарий из пяти проверок, все зелёные). Событие кражи порождает убеждение (`player`, `STOLE`, цель) с надёжностью прямого наблюдения $r = 0.9$ у свидетеля в зоне видимости; свидетель на дистанции $13.0 > 10.0$ убеждения не получает (запрет телепатии), как и свидетель за стеной (дистанция 6.0, линия взгляда перекрыта); истина мира при этом не мутируется. Повторное наблюдение того же события тем же свидетелем усиливает убеждение $0.9 \rightarrow 1.0$ (same-source буст), а вражеское свидетельство поверх наблюдения ослабляет его $1.0 \rightarrow 0.7143$ — ровно по формуле ADR-O-357, что проверяется предсказанием значения до прогона.

Слой диспозиций (S211, шесть проверок) замыкает проекцию контекста в модификаторы решений. Один и тот же `EpistemicContext` (угроза, $c = 0.9$) даёт четыре разных словаря модификаторов по архетипам: стражнику `report` = 1.89 > `warn` = 0.675, горничной `spread_rumor` = 1.755 — максимум её профиля, купцу `warn` = 1.89, а вор не получает `report`-модификатора вовсе (молчание преступника). Вызов без архетипа воспроизводит легаси-словарь S198 байт-в-байт, повторный вызов идентичен (детерминизм). Один `belief` — разные поступки по натуре: монокультура реакций мертва архитектурно, а не запретом.

5.5. Каузальность «убеждение $\rightarrow$ решение»: три уровня подтверждения

Ключевое утверждение архитектуры — каузальная значимость убеждения — подтверждено на трёх уровнях изоляции. *Уровень 1: прямой вызов `DecisionHub`.* Агент `guard_borko` с одинаковым сидом и драйвами решает `warn` со score 0.225 без эпистемических модификаторов; при модификаторах, вычисленных из контекста (угроза, $c = 0.9$, архетип `guard: report` = 1.89), выбирается `report` со score 2.093. Решение изменилось единственным входом — убеждением.

Уровень 2: полный живой цикл (позитивный контроль). Между тиками в таверну инъецируется одно мировое событие кражи (`actor` = вор). Наблюдатели определяются мембраной LOS: четыре агента (кузнец, горничная, купец, игрок) формируют убеждение (вор, `STOLE`, яблоко) с $c = 0.90$; стражник, отгороженный стеной, — нет (дистанция $8.9 < 10$, но линия взгляда перекрыта); сам вор исключён как актёр. На следующем тике очки решений свидетелей сдвигаются на диспозиционные модификаторы: кузнец (`commoner`) `warn` $0.004 \rightarrow 1.452$ (модификатор 1.35), купец `warn` $-0.098 \rightarrow 1.89$ (модификатор 1.89), горничная `talk` $0.181 \rightarrow 0.998$ (модификатор 0.81), и её интент меняется `idle` $\rightarrow$ `talk`. Актёр (вор) сохраняет очки побитово, несвидетели — лишь малый

Таблица 2: Микродинамика убеждений: измерения изолированных подсистем (V.0.5.4.0.6, среда без LLM).

Измерение	Результат
Подтверждение (trust , $w=0.60$, $ \text{cum} =2$)	$0.594 + 0.100 = 0.694$
Опровержение (та же сила)	$0.594 - 0.300 = 0.294$
Чистая асимметрия движка	$6.0\times$; эффективная $3.0\times$
Разрушение $\text{trust} = 0.60$ ($ \text{cum} =2$)	3 негативных эпизода
Полураспад веса	$\tau \ln 2 = 69.3$ тика
Горизонт забывания ($w_0=1.0 \rightarrow 0.05$)	$\tau \ln 20 = 299.6$ тика
Эхо того же источника ($c=0.40$, $r=0.40$)	$0.40 \rightarrow 0.48$
Независимый источник ($r=0.40$)	$0.40 \rightarrow 0.80$
Враждебный источник ($r = -1.0$)	$c = 0.00$
KernelRNG (42, прс_а), два прогона	последовательности идентичны

неэпистемический сдвиг (раздел 5.9). Расхождение решений порождено расхождением убеждений при тождественном мире.

Уровень 3: testimony-канал и его предусловие. Слух (COMMUNICATION_CLAIM от вора) достигает шести слушателей, но убеждение — функция доверия к рассказчику (раздел 5.7 ниже): стражник, подозревающий вора (доверие -0.4), получает $c = 0.00$, и решение не меняется (S-004/S-010 — красный вердикт). Это не разрыв провода «убеждение $\rightarrow$ решение», а работа его предусловия: каузальная сила свидетельства гейтируется надёжностью источника. Уровни 1–2 доказывают провод; уровень 3 измеряет гейт.

5.6. Микродинамика убеждений

Табл. 2 сводит измерения изолированных подсистем (все числа — вывод прогонов, а не формулы из документации). Асимметрия травмы проявляется двояко: чистый множитель движка равен 6, а эффективное отношение сдвигов при чувствительностях веток $0.25/0.50$ равно 3 — опровержение с $|\text{cum}| = 2$ сдвигает вес на 0.300, подтверждение той же силы — на 0.100. Убеждение $\text{trust} = 0.60$ разрушается тремя последовательными негативными эпизодами. Затухание: полураспад 69.3 тика, горизонт забывания 299.6 тика (для $w_0 = 1.0$). Ревизия: эхо того же источника поднимает уверенность $0.40 \rightarrow 0.48$, независимый источник — $0.40 \rightarrow 0.80$, враждебный ($r = -1$) даёт нулевую уверенность.

5.7. Живой каскад слуха

Прогон живой сцены (таверна, 6 NPC + игрок) с инъекцией одного коммуникативного утверждения «купец украл яблоко» от агента-лжеца дал записей в эпистемическом хранилище ровно по числу услышавших — и разную уверенность у разных слушателей (табл. 3): один и тот же слух, один источник, шесть эпистемических исходов. Уверенность каждого слушателя — в точности его надёжность источника $r(\tau)$: доверие по умолчанию 0.5 у агентов без истории отношений с лжецом, 0.1 у горничной (куратор гильдии, но не доверяет), 0 у трактирщика ($\tau = -0.2$) и стражника ($\tau = -0.4$, подозревает лжеца). Субъект клеветы с доверием по умолчанию полуверит обвинению в свой адрес (0.5) — самореферентный канал не подменяет доверие. Перед нами вычислительная реализация того, что в социальных эпистемологиях называется распределением убеждённости по сети доверия — и всё это — детерминированная функция состояния отношений, воспроизводимая тик за тиком.

Таблица 3: Каскад одного слуха «купец украл яблоко» (источник — агент *A*, лжец): уверенность слушателей как функция доверия к источнику.

Слушатель	Роль в сцене	Уверенность
Купец Горан	субъект клеветы (о себе)	0.50
Кузнец Орм	свидетель рядом	0.50
Игрок	наблюдатель	0.50
Горничная Люся	свидетель на краю радиуса	0.10
Трактирщик Торнин	недоверчивый слушатель ($\tau = -0.2$)	0.00
Стражник Борко	подозревает лжеца ($\tau = -0.4$)	0.00

5.8. Персистентность и замыкание на игрока

Персистентность (S-009, зелёный): инъекция лжи, два тика, сохранение сцены, перезапуск `GameLoop`, загрузка — убеждение восстановлено с той же уверенностью (0.50), эпистемическое состояние до и после перезапуска идентично. Побитовая чётность подтверждена и на уровне полного хранилища: 8 записей RAM проецируются в 8 записей сериализованного снимка с теми же уверенностями — граница «состояние → снимок» не теряет эпистемику.

Замыкание на игрока (S-014/S-015, зелёные): реплики NPC порождают убеждения игрока как функцию доверия — друг ($\tau = +50$) даёт $c = 0.80$, враг ($\tau = -50$) даёт $c = 0.00$; runtime-труба `DialogueMaterializer` → `EventBus` → `EpistemicStore[player]` работает без ручных вызовов ($c = 0.96$), а полная каузальная труба `TaskScheduler` → исполнитель → материализатор → `EventBus` → убеждения слушателей порождает за один тик три записи: игрок (0.99), свидетель-жертва (0.50) и сам говорящий (0.50).

Гейт обвинения (S211, пять проверок, зелёные) доводит принцип до геймплея: действие `ACCUSE` доступно игроку только при убеждении $c \geq 0.5$ о субъекте обвинения. Слабый слух ($c = 0.4$) блокируется, отсутствие убеждения — тоже, но ложное обвинение невиновного при твёрдой вере (0.9) проходит: движок не является арбитром истины — социальные последствия (`fear +25`, `trust -15`) применяются к цели, а расхождение веры и истины разрешают сами агенты. Убеждение — способность в буквальном смысле: игрок действует из знания, включая ошибочного.

5.9. Честный аудит: красные вердикты как диагностика

Шесть семейств проверок в исследуемом снапшоте вернули красный вердикт. Мы трактуем эти неудачи как первоклассные результаты. В системе, заявляющей исполняемые эпистемические контракты, красный вердикт ценнее тихого зелёного: он указывает ровно то место, где при данной фикстуре разорвана каузальная цепь (табл. 4).

Каузальность через testimony (S-004/S-010). Убеждение сформировалось с уверенностью 0.00: доверие стражника к лжецу в фикстуре мира отрицательно ($\tau = -0.4$, «подозревает в преступлениях»), ревизия честно обнулила слух, контекст пуст, модификаторов нет, решение не изменилось. Перед нами не разрыв цепи «убеждение → решение» — она подтверждена тремя независимыми прогонами (раздел 5.5: прямой вызов `DecisionHub`, позитивный контроль наблюдения, диспозиции S211), а работа её предусловия: каузальная сила свидетельства гейтируется надёжностью источника. Сценарий рассчитан на фикстуру с положительным доверием.

Мембрана коммуникации (S-007/S-008). Инъектированное вручную событие получает радиус по умолчанию 999: «слышат» все, включая адресата на дистанции 12.6 (убеждение $c = 0.10$). При этом мембрана канала наблюдения (ADR-O-360) проходит все пять проверок: дистанция, стены и самоисключение работают, телепатии нет. Вердикт расщепился по каналам: физика наблюдения доказана, радиус коммуникационного события не изолирован от мирового состояния.

Гэн DecisionHub (S-009-gap). Тест строит `EpistemicContext` без `max_confidence` (по умолчанию 0.0), буст модификаторов равен $0 \cdot 1.5 = 0$, и оба вызова возвращают идентич-

Таблица 4: Красные вердикты снимота V.0.5.4.0.6 (протокол свежей распаковки) и их диагностика.

Сценарий	Диагноз
S-004/S-010 (testimony)	доверие стражника к лжецу -0.4 даёт $c = 0$; пустой контекст, пустые модификаторы, решение не меняется — цепь подтверждена позитивным контролем, гейтируется доверием
S-007/S-008 (мембрана)	радиус события по умолчанию 999 допускает далёкого слушателя ($c = 0.10$ на дистанции 12.6); мембрана наблюдения проходит 5/5
S-009-gap (DecisionHub)	фикстура без <code>max_confidence</code> → нулевой буст → идентичные решения; при полном контексте $0.225 \rightarrow 2.093$
S-005/S-006 (атрибуция)	<code>base + mod</code> $\neq$ <code>final</code> : неатрибутированная деформация -0.024 от неэпистемических каналов
E2.0-с и LLM-семейство	«провод события в состояние мёртв» без LLM-среды — живой шлюз деградации не компенсирует отсутствие интерпретации
Состояние прогонов	накопление мирового состояния между прогонами меняет вердикты (краш «WARN without target»); протокол свежей распаковки обязателен

ные решения. Мы воспроизвели красный вердикт и опровергли его диагноз: при корректно заполненном контексте `DecisionHub` применяет модификаторы и меняет интен (раздел 5.5, уровень 1). Красный вердикт зафиксировал дефект фикстуры самого теста — и это тоже полезная работа контракта: оракул упал ровно там, где проекция контекста неполна.

Атрибуция модификаторов (S-005/S-006). Побитовая проверка `base + mod = final` не сходится: небольшая неатрибутированная деформация (-0.024 на каждом интене) приходит из неэпистемических каналов события (аффективная фаза, каузальный срез угрозы). Слагаемое детерминировано, но не атрибутировано контрактом — граница ответственности модификаторов размыта.

LLM-зависимые сценарии (S-011/S-012/S-013, GORAN, production). Без живого LLM-сервера провод «событие → состояние» не замыкается: деградация репортится в журнал (никаких тихих отказов), но события `NPC_SPOKE` не порождаются, второй порядок наблюдения и вертикальный срез не собираются.

Накопление состояния прогонов. Песочница сохраняет мировое состояние между запусками: после примерно дюжины накопленных тиков тик падает с «intent WARN without target» — накопленный мир выводит агента в состояние, не предусмотренное фикстурой сценария. Все вердикты этой статьи получены протоколом свежей распаковки; без него вердикты воспроизводятся плохо. Это прямая демонстрация тезиса «оракул зависим от мирового состояния» — на уровне самого инструментария.

Мы приводим оба ряда — красные, полученные в этом снимоте, и зелёные, зафиксированные в более ранних авторских средах (журнал мутаций: мембрана S192.1, дивергенция решений S194, каузация действия S195, каузация события мира S196, наблюдение второго порядка S198a, канал наблюдения S207 5/5, диспозиции S211 6/6, GORAN 12/12), — потому что их сопоставление и есть суть метода. Система, отчитывающаяся только зелёным, неverifiedируема. Исполняемые контракты полезны именно тогда, когда умеют падать громко и указывать конкретный разрыв.

6. Обсуждение и ограничения

Что даёт инженерная проверяемость эпистемики. Главный практический результат архитектуры — возможность отвечать на эпистемические вопросы прогона, а не опросом модели. Откуда агент узнал факт (провенанс трейса), насколько уверен (уверенность записи с провенансом источника), почему изменил решение (модификаторы, вычисленные из убеждений, с трассировкой причинного утверждения) — всё это читаемые, детерминированные функции состояния. Для исследователей это превращает «поведенческие» утверждения об агентах в измеримые; для разработчиков игр — даёт каузальную альтернативу скриптам «NPC просто знает». Существенно

и то, что детерминизм не делает мир предсказуемым для игрока: воспроизводимость механики и информационная непредсказуемость — ортогональные свойства, разделённые эпистемической границей наблюдателя.

Асимметрия как инженерное решение. Множитель травмы 6 — не вывод из психологических данных, а калибровочная константа, формализующая negativity bias в вычислимой форме. Её значение проверяемо: отношение сдвигов опровержения и подтверждения измеряется напрямую (раздел 5), а чувствительности веток модулируют эффективную асимметрию ($3 \times$ при $s_{\text{fear}}=0.25$, $s_{\text{signif}}+s_{\text{desire}}=0.50$). Такая явность выгодно отличает систему от LLM-агентов, где «памятливость обиды» — неявное свойство промптов.

Ограничения. Мы перечисляем их явно, в соответствии с принципом «не претендовать на большее, чем доказано сценариями». (1) Полноценная Theory of Mind не заявляется: наблюдение второго порядка задокументировано в авторской среде (S198a), но в исследуемом снапшоте требует живого LLM-сервера и не воспроизводится без него; предикат ASSERTS существует, каскады глубже — нет. (2) Несколько оракулов сценариев всё ещё зависят от состояния мира (отношения, позиции, радиусы по умолчанию, накопленные прогонами тики). Как показывает аудит S-004 и S-008, это делает вердикт чувствительным к фикстуре. Изоляция контрактов за явными мировыми преусловиями остаётся будущей работой. (3) В BeliefState сосуществуют два легальных writer’а (реактивная ветка и агрегатор когерентности) — задокументированный компромисс R8 без семантики мёрджа. (4) Недетерминизм async-interleaving (DEBT-QUIESCE) остаётся открытым долгом воспроизводимости. (5) Масштаб: одна локация, 6 NPC; масштабирование до сотен агентов не измерялось. (6) Константы калиброваны эвристически; количественного сравнения с базовыми подходами (LLM-агенты с памятью) не проводилось — работа позиционируется как systems contribution, и её оценка — выполнимость и воспроизводимость контрактов, а не превосходство поведения.

7. Заключение

Мы предъявили детерминированную многоагентную архитектуру, в которой расхождение убеждений агентов — первоклассное, каузально значимое и исполняемое проверяемое свойство симуляции, а не побочный эффект языковой генерации. Архитектурную основу составляют опыт с первоклассным провенансом, мембрана восприятия, шлюз DeltaGate, изолирующий LLM от каузального ядра, и асимметричная кристаллизация убеждений; методологическую — исполняемые эпистемические контракты, превращающие утверждения об архитектуре в бинарные воспроизводимые вердикты. Прогоны подтвердили работоспособность ядра (45/45 инвариантов), детерминированность и измеримость эпистемической микродинамики, распределение уверенности одного слуха по сети доверия, каузальность «убеждение → решение» на трёх уровнях изоляции и — в равной мере — информативность красных вердиктов как средства аудита. Будущая работа: поведенческое замыкание (Behavioral Closure), унифицированная оценка (affective appraisal), изоляция оракулов сценариев от мирового состояния и количественная калибровка констант. Мы рассматриваем ENIGMA не как «ещё одну LLM-песочницу», а как попытку сделать эпистемику агентов инженерно проверяемой. Приглашение к сообществу конкретно: инструмент, породивший зелёные и красные вердикты этой статьи, публичен. Проверьте утверждения контрактами.

Доступность

Полный исходный код, журнал мутаций, архитектурные ADR и сценарии SUPERBOX доступны в репозитории проекта: <https://github.com/4Um4/Enigma/> (ветка V.0.5.4.0.6_Кушаем_1). Все прогоны статьи исполняются в среде без LLM-сервера из свежераспакованного архива релиза. Быстрая проверка ядра (около 5 секунд, LLM не требуется):

```
python backend/tests/IPT.py
```

Контрактные сценарии разделов 4 и 5 (из каталога `backend`, каждый — в свежей распаковке):

```
python tests/sandbox/SUPERBOX/scenarios/epistemic_core_test.py
python tests/sandbox/SUPERBOX/scenarios/epistemic_observation_test.py
python tests/sandbox/SUPERBOX/scenarios/epistemic_dispositions_test.py
python tests/sandbox/SUPERBOX/scenarios/epistemic_persistence_test.py
python tests/sandbox/SUPERBOX/scenarios/epistemic_player_belief_test.py
python tests/sandbox/SUPERBOX/scenarios/accusation_gate_test.py
python tests/sandbox/SUPERBOX/scenarios/epistemic_causal_test.py
```

Позитивный контроль каузальности (раздел 5.5, уровень 2) публикуется вместе со статьёй: инъекция события THEFT через штатный EventBus между тиками с последующим сравнением интенгов ветвей control/treatment. Микроизмерения раздела 5 воспроизводятся изолированными прогонами модулей движка: кристаллизации убеждений, ревизии убеждений и генератора KernelRNG.

Список литературы

- [1] Park J. S., O’Brien J. C., Cai C. J., Morris M. R., Liang P., Bernstein M. S. Generative agents: Interactive simulacra of human behavior // arXiv preprint arXiv:2304.03442. 2023. <https://arxiv.org/abs/2304.03442>
- [2] OASIS: Open agent social interaction simulations with one million agents // arXiv preprint arXiv:2411.11581. 2024. <https://arxiv.org/abs/2411.11581>
- [3] Sagara R. et al. BeliefNest: A joint action simulator for embodied agents with theory of mind // arXiv preprint arXiv:2505.12321. 2025. <https://arxiv.org/abs/2505.12321>
- [4] Wang L., Ma C., Feng X. et al. A survey on large language model based autonomous agents // Frontiers of Computer Science. 2024. Vol. 18. No. 6. P. 186345.
- [5] Alchourrón C. E., Gärdenfors P., Makinson D. On the logic of theory change // Journal of Symbolic Logic. 1985. Vol. 50. No. 2. P. 510–530.
- [6] Rozin P., Royzman E. B. Negativity bias, negativity dominance, and contagion // Personality and Social Psychology Review. 2001. Vol. 5. No. 4. P. 296–320.
- [7] Baumeister R. F., Bratslavsky E., Finkenauer C., Vohs K. D. Bad is stronger than good // Review of General Psychology. 2001. Vol. 5. No. 4. P. 323–370.
- [8] Premack D., Woodruff G. Does the chimpanzee have a theory of mind? // Behavioral and Brain Sciences. 1978. Vol. 1. No. 4. P. 515–526.
- [9] Wimmer H., Perner D. Beliefs about beliefs: Representation and constraining function of wrong beliefs in young children’s understanding of deception // Cognition. 1983. Vol. 13. No. 1. P. 103–128.
- [10] Meyer B. Applying “design by contract” // IEEE Computer. 1992. Vol. 25. No. 10. P. 40–51.
- [11] Leucker M., Schallhart C. A brief account of runtime verification // The Journal of Logic and Algebraic Programming. 2009. Vol. 78. No. 5. P. 293–303.
- [12] Laird J. E. The Soar cognitive architecture. Cambridge, MA: MIT Press, 2012.